



下載

能源轉換與管理

第165卷 · 2018年6月1日 · 第681-695頁

利用深度學習時間序列預測和極值優化的非線性學習集成進行風速預測

解 陳^a 曾國強^b, 武能週^{a, c, d}, 衛都^a, 康帝路^a

展示更多 ∨

⋮ 大綱

🔗 分享

📄 引用

<https://doi.org/10.1016/j.enconman.2018.03.098>

獲取權利和內容

強調

- 提出了一種新型的深度學習時間序列預測的非線性學習集合，用於風速預測。
- 引入了具有不同隱藏層和神經元的LSTM簇，以探索和利用風速時間序列。
- 開發了一種由SVRM組成的非線性學習回歸頂層，以進行整體預測。
- 採用極值優化算法搜索頂層SVRM的最優參數。
- 通過從中國一家風電場收集的兩個案例研究數據驗證了擬議的EnsemLSTM的有效性。

抽象的

風速預測作為風能行業的重要問題，在風能發電和轉換的最佳調度和控制中起著至關重要的作用。在本文中，通過使用基於LSTM（長期短期記憶神經網絡），SVRM（支持向量回歸機）和EO（極端優化算法）的深度學習時間序列預測的非線性學習集合，提出了一種稱為EnsemLSTM的新方法。首先，為了避免單一深度學習方法在面對多樣化數據時產生偏差和魯

FEEDBACK

棒性的缺點，我們採用了具有不同隱藏層和神經元的LSTM簇來探索和利用風速時間序列的隱式信息。然後將LSTM的預測匯總到由SVRM組成的非線性學習回歸頂層中，並引入EO來優化頂層參數。最後，由微調的頂層給出風速的最終合奏預測。擬議的EnsemLSTM用於從中國內蒙古的一個風電場收集的兩個案例研究數據，以進行最大提前短期風速預測10分鐘和提前短期風速預測1小時。與其他流行的預測模型相比，實驗結果的統計測試證明了所提出的EnsemLSTM可以實現更好的預測性能。擬議的EnsemLSTM用於從中國內蒙古的一個風電場收集的兩個案例研究數據，以進行最大提前短期風速預測10分鐘和提前短期風速預測1小時。與其他流行的預測模型相比，實驗結果的統計測試證明了所提出的EnsemLSTM可以實現更好的預測性能。擬議的EnsemLSTM用於從中國內蒙古的一個風電場收集的兩個案例研究數據，以進行最大提前短期風速預測10分鐘和提前短期風速預測1小時。與其他流行的預測模型相比，實驗結果的統計測試證明了所提出的EnsemLSTM可以實現更好的預測性能。

[← 上一頁](#)[接下來 →](#)

關鍵字詞

風速預報; 深度學習; 時間序列預測; LSTM (長期短期記憶神經網絡); 合奏學習; 極端優化

1. 介紹

作為減少溫室氣體排放並建立可再生社會的有前途的實用解決方案，風能在各個國家越來越受歡迎。全球風能理事會 (GWEC) 於2017年發布的全球風能報告指出，2016年世界風電市場超過54.6 GW，導致全球總裝機容量接近487 GW，仍由中國領先，美國，德國和印度[1]。未來幾年，風能的容量將繼續大幅增長。然而，由於風速的自然不規則特性，在電力系統中執行可靠且及時的風能管理可能是一項艱鉅的任務。不穩定且不可控制的風速嚴重影響了風力發電，隨後將影響風力發電機的控制，電力系統和微電網調度，電能質量以及供需平衡[2]，[3]。因此，可靠，準確的風速預測不僅可以為風能的產生和轉換提供安全的基礎，而且可以降低電力系統運行的成本。

現有的風速預測方法可以分為物理模型，統計模型和人工智能模型三類。物理模型是簡單的方法，它利用了諸如氣壓，溫度，障礙物和粗糙度等物理信息[4]。其中，NWP (數值天氣預報) 模型採用了一組基於物理信息的數學方程來進行預測。此外，近幾十年來已經研究了一系列統計模型來進行風速預測。廣泛使用的統計模型包括自回歸模型 (AR)，移動平均模型 (MA)，自回歸移動平均模型 (ARMA)，自回歸綜合移動平均值模型 (ARIMA) 和季節性自回歸綜合移動平均值 (SARIMA)。Liu [5]提出了一種基於遞歸ARIMA和EMD (經驗模態分解) 的新方法，用於鐵路強風預警系統的短期風速預測。Kavasseri等。[6]開發了一個ARIMA分數，以預測北達科他州一天和未來兩天的風速。另一方面，隨著軟計算技術的飛速發展，已經成功地提出了用於時間序列預測的人工智能模型。其中，ANN (人工神經網絡) 例如反向傳播神經網絡[7]，多層感知器神經網絡[8]，徑向基函數神經網絡[9]，貝葉斯神經網絡[10]和極限學習機 [11]]已應用於風速預測。Chang等。[12]提供了一種改進的

的方法，該方法具有錯誤反饋功能，可預測短期風速和功率。Noorollahi等。[13]成功地使用ANN模型對伊朗進行了時空風速預測。在[14]中，Ma等。提出了一種用BSO優化的廣義動態模糊神經網絡（腦風暴優化）來預測短期風速。另一個受歡迎的群體是具有高泛化能力的SVM（支持向量機）。江等。文獻[15]提出了一種使用布穀鳥搜索算法優化的 ν -SVM的混合短期風速預測模型。Chen等。[16]用無味卡爾曼濾波器開發了一種基於狀態空間的支持向量機用於風速預測。另外，為了提高單個模型的預測性能，最近對組合模型或混合模型進行了研究以解決該問題[17]，[18]。對於組合方法，將使用不同的單個模型進行預測，並將它們的預測結果進行組合，以給出具有相應權重係數的最終預測。肖等。[18]提出了一種基於無負約束理論和人工智能算法的新型組合模型，其中使用混沌粒子群優化算法來找到最優權重係數。為了同時獲得高精度和強穩定性，Wang等人。[19]開發了使用多目標蝙蝠算法的組合預測模型進行風速預測。在[20]，Wang等。提出了一種採用ARIMA，SVM，ELM和LSSVM（最小二乘支持向量機）進行短期概率風速預測的魯棒組合模型，其中利用GPR（高斯過程回歸）來組合各個預測變量的結果。最近的研究表明，組合預測機制比單個模型可以實現更好的預測性能。然而，應該指出的是，普遍接受的權重係數組合策略是一種線性方法，無法找到各個模型的非線性關係。此外，需要引入更高級的預測方法來增強預測性能，而不是像ANN和SVM這樣的常規機器學習算法。

近年來，深度學習在時間序列建模中的應用引起了人們的廣泛研究興趣[21]。呂等人。[22]使用深度學習方法對大數據進行交通流量預測。邱等。[23]提出了一種用於電力負荷預測的集成深度學習方法。此外，先進的深度學習方法也已成功地應用於風速預測領域。在[24]中，Hu等人。提供了一種基於深度自動編碼器的模型，該模型使用轉移學習進行短期風速預測。Khodayar [25]提出了帶有自動編碼器的粗略深度神經網絡架構，以進行短期風速預測。王[26]開發了一種新的使用深度置信網絡模型的確定性和概率風速預測方法。此外，集成學習已被廣泛認可，通過智能地組合併行學習模型可以提高學習性能[27]。儘管可以將現有的風速預測組合模型視為整體預測的一種類型，但它們的預測結果幾乎都是線性組合各個預測變量。從一般合奏學習的角度出發，應進一步探索和研究基於非線性學習的合奏預測。因此，在本研究中，提出了一種基於LSTM（長短期記憶神經網絡），SVRM（支持向量回歸機）和EO（極值優化算法）的深度學習時間序列預測的非線性學習集合的新方法，稱為EnsemLSTM。用於風速預測。LSTM作為RNN（遞歸神經網絡）的突破性變體，與傳統RNN相比，可以從時間序列數據中深入學習時間和長期依存關係，並有效地解決了消失的梯度問題[31]，[32]。EO是統計物理學領域一種很有前途的新型智能優化算法，已應用於許多組合和連續優化問題，這表明它比GA和PSO等常用算法更具有優勢[37]，[38]，[39]，[40]，[41]。受整體學習啟發，具有不同隱藏層和神經元的LSTM簇首先介紹瞭如何探索和利用風速時間序列的隱藏信息。為了克服傳統組合模型線性表示的缺點，將LSTM的預測匯總到非線性學習回歸頂層中，以給出最終的整體預測，而不是線性組合。人工神經網絡是一種經典的人工智能方法，但是它很不穩定，其性能在很大程度上取決於數據，這使得很難預先定義網絡的結構。另外，由於訓練算法的限制，人工神經網絡可能容易陷入局部極小[28]。相反，SVRM在解決複雜的非線性回歸方面具有優勢和預測問題，並在預測領域獲得了廣泛的應用並取得了顯著的成功[29]，[30]。因此，本文使用的非線性學習頂層由SVRM組成，以克服ANN的弱點，並引入EO來搜索該頂層的最佳參數。因此，總結了所提議的EnsemLSTM與傳統組合模型之間的主要區別：（a）：LSTM，在EnsemLSTM中引入了一種深度學習方法作為預測引擎，而傳統組合模型的預測器則是常規的機器學習算法，例如ANN和支持向量機（b）：為克服傳統組合模

型的線性表示的缺陷，在EnsemLSTM中採用了非線性學習回歸頂層來進行最終的整體預測；

(c)：一種新穎的有前途的智能優化算法的應用，即

本文的主要貢獻如下：(1) 引入了基於LSTM的深度學習時間序列預測，以探索和利用風速時間序列的隱含信息進行風速預測；(2) 為了提高單一深度學習方法的泛化能力和魯棒性，深度學習時間序列預測的非線性學習集合由具有不同隱藏層和神經元的LSTM簇和一個由開發了通過EO優化的SVRM；(3) 擬議的EnsemLSTM的性能已通過從風電場收集的兩個案例研究數據成功驗證在中國內蒙古，最大風速要提前10分鐘，而風速要提前1小時。實驗結果的統計測試表明，與其他預測模型相比，擬議的EnsemLSTM可以實現更好的預測性能。

本文的其餘部分安排如下。在第2，深度學習時間序列預測風速預報的非線性學習合奏的優化問題製劑提出並引入有關的基本學習和優化算法。第3節介紹了擬議的EnsemLSTM。第四部分描述了模型預測性能的評估指標。在第5節中，進行了兩個案例研究，並且在本節中還對預測模型進行了討論和比較。最後，第六部分給出了本文的結論和今後的工作。

2. 問題表述

2.1. 深度學習時間序列預測

作為一種獨特的RNN，LSTM利用稱為記憶塊的特殊單位來代替隱藏層中的傳統神經元[31]，[32]。此外，在存儲塊中存在三個稱為輸入門，輸出門和遺忘門的門單元，因此LSTM具有更新和控制通過這些門的塊中信息流的能力。LSTM的架構顯示在圖1中。下面可以遵循更新單元狀態併計算LSTM輸出的實現。

$$\text{input gate: } i_t = \sigma(W_{ix}x_t + W_{ip}p_{t-1} + W_{ie}e_{t-1} + b_i) \quad (1)$$

$$\text{output gate: } o_t = \sigma(W_{ox}x_t + W_{op}p_{t-1} + W_{oe}e_t + b_o)$$

$$\text{forget gate: } f_t = \sigma(W_{fx}x_t + W_{fp}p_{t-1} + W_{fe}e_{t-1} + b_f)$$


$$\text{temporary cell state: } \tilde{e}_t = g(W_{ex}x_t + W_{ep}p_{t-1} + b_e)$$

$$\text{cell state: } e_t = i_t \odot \tilde{e}_t + f_t \odot e_{t-1}$$

$$\text{output: } p_t = o_t \odot h(e_t)$$

$$\text{output layer: } y_t = \varphi(W_{yp} \cdot p_t + b_y)$$

其中 x_t 是輸入向量， y_t 是輸出向量， i_t ， o_t 和 f_t 分別是輸入門，輸出門和忘記門的輸出， \tilde{e}_t 和 e_t 是在存儲器塊中的存儲單元的暫時的和精加工的狀態， p_t 是存儲塊的輸出。 σ 表示門激活函數（通常為邏輯S型函數）， g 和 h 分別是輸入和輸出激活函數（通常為tanh函數）， \odot 是兩個向量之間的逐元素乘法（Hadamard乘積）， φ 是LSTMs的輸出激活功能，在本文中對於時間序列的預測的線性函數而 $W_{ix}^-, w_{ip}^-, w_{ie}^-, w_{ix}^+, w_{ip}^+, w_{ie}^+, w_{ox}^-, w_{op}^-, w_{oe}^-, w_{ox}^+, w_{op}^+, w_{oe}^-, w_{fx}^-, w_{fp}^-, w_{fe}^-, w_{fx}^+, w_{fp}^+, w_{fe}^-, w_{ex}^-, w_{ep}^-, w_{ey}^-, w_{ex}^+, w_{ep}^+, w_{ey}^+$ 代表相應的權重矩陣 b_i, b_o, b_f, b_e 和 b_y 是相關的偏差向量。



下載：下載高分辨率圖像 (158KB)

下載：下載全圖

圖1。LSTM的架構。

2.2。深度學習時間序列預測的非線性學習集合用於風速預測

為了實現更好的風速預測，本文開發了基於LSTM，SVRM和EO的深度學習時間序列預測的非線性學習系統。在非線性學習集成學習的結構中，將一組LSTM的預測輸入到非線性學習回歸頂層中以產生最終預測。考慮到解決複雜回歸問題的優越性和廣泛的應用以及在預測領域的巨大成功[29]，[30]，SVRM作為非線性學習頂層被引入。但是，集成學習的性能在很大程度上取決於頂層SVRM的參數，即懲罰係數 C 和內核參數 σ 。為了解決這個問題，本文成功開發了使用實編碼EO的SVRM參數優化。在給出風速預測的優化問題公式之前，首先介紹了SVRM和EO的基本概念。

2.2.1。支持向量回歸機

給定一組樣本 $\{\mathbf{X}_{\text{我}}, \mathbf{y}_{\text{我}}\}$ ， $\text{我} = 1, 2, 3, \dots, \tilde{N}$ ，與輸入矢量 $\mathbf{X}_{\text{我}} \in [\mathbb{R}^k$ 和輸出向量 $\mathbf{y}_{\text{我}} \in [\mathbb{R}$ 。回歸問題的任務是找到一個函數 $f(\mathbf{x})$ 來揭示輸入和輸出的關係。SVR的動機是在高維特徵空間中實現線性回歸，該高維特徵空間是通過預定義函數映射原始輸入集而獲得的 $\phi(\mathbf{x})$ 並最小化結構風險 $R[f]$ [28]，[29]，[30]。並且以上過程可以表示如下。

$$f(\mathbf{x}) = \mathbf{W}^T \phi(\mathbf{x}) + b \quad (2)$$

$$R[f] = \frac{1}{2} \|\mathbf{W}\|^2 + C \sum_{i=1}^N L(\mathbf{x}_i, \mathbf{y}_i, f(\mathbf{x}_i))$$

其中 \mathbf{W} ， b 和 C 分別是回歸係數向量，偏差項和懲罰係數， $L(\mathbf{x}_i, \mathbf{y}_i, f(\mathbf{x}_i))$ 表示 ϵ 不敏感損失函數。可以通過以下約束優化問題來解決回歸問題：

$$\min \quad \frac{1}{2} \|\mathbf{W}\|^2 + C \sum_{i=1}^N (\zeta_i + \zeta_i^*) \quad (3)$$

$$\text{s.t.} \quad \mathbf{y}_i - (\mathbf{W}^T \phi(\mathbf{x}_i) + b) \leq \epsilon + \zeta_i$$

$$(\mathbf{W}^T \phi(\mathbf{x}_i) + b) - \mathbf{y}_i \leq \epsilon + \zeta_i^*$$

$$\zeta_i, \zeta_i^* \geq 0 \quad i = 1, 2, 3, \dots, N$$

在哪裡 ζ_i 和 ζ_i^* 表示鬆弛變量以使約束可行。通過引入拉格朗日乘數，可以給出如下回歸函數

$$f(x) = \sum_{i=1}^N (\alpha_i - \alpha_i^*) K(x_i, x_j) + b \quad (4)$$

在哪裡 α_i 和 α_i^* 是滿足條件的拉格朗日乘數 $\alpha_i \geq 0, \alpha_i^* \geq 0$ 和 $\sum_{i=1}^N (\alpha_i - \alpha_i^*) = 0$ 。 $K(x_i, x_j)$ 是核函數，本文選擇常用的徑向基函數 (RBF) 作為核函數，定義為

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) \quad (5)$$

其中 σ 表示RBF內核寬度。

2.2.2。極端優化

EO [33]，[34]，是一種新穎的有前途的智能優化算法，這刺激了由自組織臨界從統計物理字段[35]，[36]。在過去的十年中，EO已成功應用於各種基準測試和實際工程優化問題[37]，[38]，[39]，[40]，[41]。相關研究表明，具有更簡單進化操作的EO可以勝過GA和PSO等常用的優化算法。下面顯示了採用PLM的實編碼 τ - EO的算法步驟。

輸入：變量總數 N ，最大迭代次數 I_{\max} ，概率分佈 $P(k)$ 的控制參數 τ 。

輸出：由EO優化的最佳解決方案。

步驟1：隨機生成初始解 S ，其中 S 是計數為 $L = N$ 的變量的組合。設置 $S_{\text{best}} = S$ 並根據預定義的適應度函數計算適應度 $C(S_{\text{best}}) = C(S)$ 。

步驟2：對於當前的解決方案 S ，

(a) 中生成的溶液 \tilde{x}_i 我通過突變部件我 ($1 \leq i \leq \tilde{N}$) (即對應的變量由PLM突變) 並保持其他不變，然後計算健身 $C(\tilde{x}_i)$ ；

PLM可以通過以下方程式解釋：

$$\begin{aligned} x' &= x + \alpha \cdot \beta_{\max} \\ \alpha &= \begin{cases} (2r)^{1/(q+1)} - 1, & \text{if } r \leq 0.5 \\ 1 - [2(1-r)]^{1/(q+1)}, & \text{otherwise} \end{cases} \quad (6) \\ \beta_{\max} &= \max[x - l, u - x] \end{aligned}$$

其中 x 表示變量的當前值， x' 是突變值， q 是PLM參數， r 是屬於 $[0,1]$ 的隨機數，而 l ， u 分別是變量的下界和上限。

(b) 中評估本地健身 $\lambda_i = C(\tilde{x}_i) - c^{\wedge}$ 最好為每個組件我和秩所有根據部件 λ_i ，即找到一個排列 Π_1 標籤的我使得 $\lambda_{\Pi_1(1)} \leq \lambda_{\Pi_1(2)} \leq \dots \leq \lambda_{\Pi_1(\tilde{n})}$ ；

(c) 中選擇的秩 $\Pi_1(k)$ 根據概率分佈 $P(k) \propto k^{-\tau}, 1 \leq k \leq n$ ，其中 τ 是一個正參數，並將對應的分量表示為 x_j ；

(d) 改變 x_j 的值，並設置 $S_{\text{new}} = S$ ，其中僅 x_j 值被突變；

(e) 如果 $C(S_{\text{new}}) < C(S_{\text{best}})$ ，則 $S_{\text{best}} = S_{\text{new}}$ ， $C(S_{\text{best}}) = C(S_{\text{new}})$ ；

(f) 無條件 接受 S_{new} ;

步驟3：重複步驟2，直到滿足一些預定義的停止標準（即，最大迭代次數 I_{max} ）。

步驟4：獲得代表最佳變量的最佳解 S_{best} 和相應的最佳適應度 C_{best} 。

2.2.3。深度學習時間序列預測的非線性學習集合的優化

從優化的角度來看，如何選擇非線性學習頂層的最佳參數作為風速預測的深度學習時間序列預測的集合，可以看作是一個典型的優化問題，其描述如下：


$$\begin{aligned} \min \quad & f = \text{Fitness}(C, \sigma) \\ \text{s.t.} \quad & l_C \leq C \leq u_C \\ & l_\sigma \leq \sigma \leq u_\sigma \end{aligned} \quad (7)$$

其中 C 和 σ 分別代表SVRM的懲罰係數和內核參數。的 l_C 和 u_C 是的下限和上限 C 和 l_σ 和 u_σ 是的下界和上界 σ 。在本文中，將預定義的 **Fitness** 函數選擇為火車數據集上的3-cross-validation的MSE（均方誤差）。為了簡化起見，選擇適應性最差的變量而不是通過概率分佈 $P(k)$ 。

3。提出的深度學習時間序列預測方法的非線性學習集合

作為一種出色的深度學習時間序列預測方法，LSTM可以有效地探索和利用動態時間序列的隱藏信息，但是LSTM的預測能力可能會受到LSTM中隱藏層的數量和每個隱藏層中神經元數量的影響。受到集成學習的出色性能的啟發，本文提出了一種基於LSTM，SVRM和EO的深度學習時間序列預測方法的非線性學習集成，稱為EnsemLSTM。

在提議的EnsemLSTM中，時間序列（即風速時間序列數據）是由具有不同數量的隱藏層和神經元的LSTM簇分別預測的首先在每個隱含層中，探索和利用風速時間序列的隱含信息。然後，為了克服傳統組合模型線性表示的缺陷，將一個非線性學習回歸頂層應用於集合預測，並由這些LSTM的預測結果進行饋送和訓練。考慮到在預測領域的廣泛應用和非凡的成功，所使用的非線性學習頂層由SVRM組成，並引入了採用PLM的實編碼EO來優化頂層參數。最後，由微調的頂層輸出風速的最終合奏預測。擬議的帶有 K 個LSTM的EnsemLSTM的總體結構如圖2所示。應該指出的是，沒有任何理論知識可以為特定數據預定義LSTM的網絡結構，而實際的解決方案是通過反複試驗選擇超參數[42]，[43]。為了在學習性能和模型複雜性之間進行權衡，在提議的EnsemLSTM中，根據試錯採用了六種不同的LSTM，分別是具有1個隱藏層的LSTM1和50個神經元的隱藏層，具有1個隱藏層的LSTM2在隱藏層中包含100個神經元，在1個隱藏層中包含LSTM3，在隱藏層中包含150個神經元，在2個隱藏層中包含LSTM4，在隱藏層中包含50,50個神經元，在2個隱藏層中包含LSTM5，在隱藏層中包含50,100個神經元，以及LSTM6具有2個隱藏層和50,150個神經元。像傳統的組合模型一樣，構建了六個不同的LSTM（LSTM1-LSTM6），作為單個預測模型來預測火車和測試數據集上的風速。火車數據集上六個LSTM模型的預測是作為火車特徵輸入到SVRM中進行學習的。SVRM的任務是學習六個LSTM預測變量的非線性關係，例如解決多元回歸問題。然後，將六個LSTM模型在測試數據集上的預測結果作為測試特徵輸入到訓練有素的SVRM中，以產生整體預測。提出的EnsemLSTM的輸出是將EO優化為最終風速預測的SVRM的整體預測。通過採用PLM的實編碼EO優化的懲罰係數 C 和核參數 σ 的搜索範圍分別為 $[0, 1000]$ 和 $[0, 1]$ 。EO中的PLM參數 q 設置為30，最大迭代次數 $I_{\text{最多}}$ 為1000。

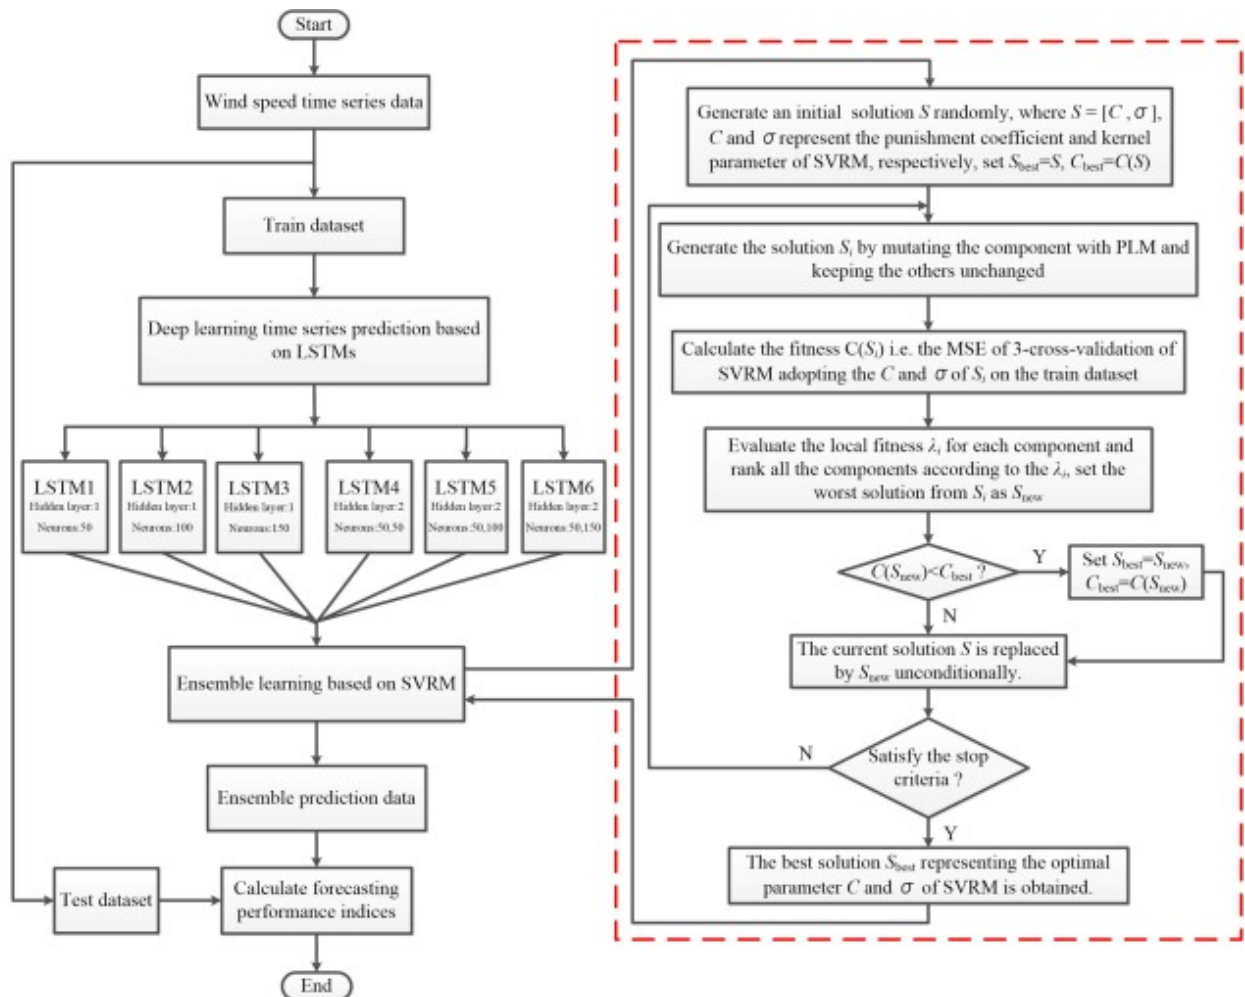


下載：下載高分辨率圖像 (143KB)

下載：下載全圖

圖2。提議的帶有K LSTMs的EnsemLSTM的結構。

EnsemLSTM的流程圖如圖3所示，該提議的EnsemLSTM的詳細實現方式在附錄中列出。



16

下載：下載高分辨率圖像 (513KB)

下載：下載全圖

圖3。此提議的EnsemLSTM的流程圖。

4. 評估預測績效

四個常用的統計標準用於評估風速預測模型的預測性能。它們的定義如下。

平均絕對誤差 (MAE) :

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |f(i) - h(i)| \quad (8)$$

均方根誤差 (RMSE) :

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (f(i) - h(i))^2} \quad (9)$$

平均絕對百分比誤差 (MAPE) :

$$\text{MAPE} = \frac{1}{N} \sum_{i=1}^N \frac{|f(i) - h(i)|}{h(i)} \times 100\% \quad (10)$$

相關係數 (R) :

$$R = \frac{\sum_{i=1}^N (f(i) - \bar{f})(h(i) - \bar{h})}{\sqrt{\sum_{i=1}^N (f(i) - \bar{f})^2} \cdot \sqrt{\sum_{i=1}^N (h(i) - \bar{h})^2}} \quad (11)$$

在哪裡 $f(i)$ 和 $h(i)$ 分別代表時間 i 的預測值和實際值。和 \bar{f} 和 \bar{h} 分別表示預測值和實際值的平均值。 N 是數據總數。


5. 實驗

5.1. 風速數據說明

中國內蒙古位於季風區，年平均風速約為 3.7 m/s 。內蒙古的風能儲量非常大，約為2.7億千瓦時，約佔總儲量的1/5，居中國首位。本文將擬議的EnsemLSTM應用於風電場收集的風速數據在中國內蒙古進行了兩個具有不同預測時間範圍的案例研究，即提前提前十分鐘進行了短期風速預測和提前了一小時進行了短期風速預測，以驗證EnsemLSTM的有效性，並將實驗結果與包括ARIMA在內的常規預測方法進行了比較，SVR，KNN，ANN和GBRT（梯度增強回歸樹）。根據AIC和BIC的值確定ARIMA的參數。對於SVR模型，根據[44]選擇C作為 $y_{\max} - y_{\min}$ ，並通過基於[45]的嘗試性實驗確定參數 σ 。預定的KNN模型（即鄰居的數量）設置為5。ANN模型由一個隱藏層組成，神經元的數量由試驗決定。對於GBRT，將最大樹深度設置為3，將決策樹的數量設置為300。在不失一般性的情況下，在以下實驗中將回溯時間滯後設置為1。換句話說，用於預測下一個點 $S(t+1)$ 的預測方法是基於最後一個點數據 $S(t)$ ，即輸入由上一次的風速值組成。ARIMA和ANN模型分別在MATLAB的計量經濟學工具箱和神經網絡工具箱中可用。SVR，KNN和GBRT模型是使用Python 2.7中的scikit-learn機器學習包執行的[46]。所提出的EnsemLSTM是通過基於MATLAB和Python 2.7的混合語言編程實現的，而LSTMs算法是通過使用“Keras”深度學習軟件包進行操作的[47]。所有型號均在裝有Windows 10操作系統，Intel Core i5 CPU @ 2.30 GHz和8.00 GB RAM的計算機上運行。考慮到隨機性的影響，每個實驗進行30次，然後取統計結果。

5.2 。案例研究1：最大程度的短期風速預測

在本案例研究中，將從2012年11月23日至2012年11月28日的每10分鐘採樣的風速數據用作數據集，以提前10分鐘進行最大的短期風速預測。在案例研究1中收集的風速顯示在圖4中。將總共738個獲得的樣本分為兩部分（70%作為訓練集，30%作為測試集）。通過訓練數據集對預測模型進行訓練，並在測試數據集上進行了驗證。上述數據集的統計信息如表1所示。表2顯示了案例研究1中不同比較預測方法的參數集。表3列出了不同預測模型的預測結果。圖5可視化了預測性能的比較。為了與建議的方法和其他預測模型進行全面比較，使用統計檢驗（包括Friedman，Friedman Aligned和Quade檢驗）對具有更高統計可靠性的不同方法進行排名[48]。表4顯示了案例研究1中通過統計測試獲得的等級，統計數據和相關的p值。6，7和8分別提供預測殘留誤差的條形圖和線圖表為不同的預測方法。



[下載：下載高分辨率圖像（98KB）](#)

[下載：下載全圖](#)

圖4。案例研究1中收集的風速

表1。案例研究1中風速的統計信息

| 案例1：2012年11月23日至2012年11月28日的十分鐘風速數據（m/s） | | | | | |
|--|--------|--------|-------|--------|-------|
| 數據集 | 最大限度 | 中位數 | 敏 | 意思是 | 標準差 |
| 整個數據集 | 18.500 | 12.100 | 5.500 | 12.166 | 2.460 |
| 訓練數據集 | 18.500 | 12.300 | 5.500 | 12.438 | 2.269 |
| 測試數據集 | 18.300 | 11.600 | 6.300 | 11.531 | 2.761 |

St.d：標準偏差。


表2。案例研究1中不同比較預測方法的參數集

| 預測方法 | 參數集 |
|--------|---|
| 酶標 | $q = 30$ ，我 _{最大} = 1000 |
| 有馬 | $(p \cdot d \cdot q) = (2 \cdot 0 \cdot 1)$ |
| SVR | $\zeta = 13.00$ ， $\sigma^2 = 0.25$ |
| 人工神經網絡 | 1個具有15個神經元的隱藏層 |
| 知識網絡 | $K = 5$ |
| GBRT | 樹的最大深度設置為3，決策樹的數量設置為300 |

表3。案例研究1中預測模型的預測結果。

| 預測方法 | MAE | RMSE | MAP (%) | [R |
|--------|---------------|---------------|---------------|---------------|
| 酶標 | 0.5746 | 0.7552 | 5.4167 | 0.9619 |
| 有馬 | 0.6961 | 0.9257 | 6.5067 | 0.9420 |
| SVR | 0.5834 | 0.7729 | 5.4912 | 0.9599 |
| 人工神經網絡 | 0.6332 | 0.8397 | 6.1528 | 0.9545 |
| 知識網絡 | 0.6391 | 0.8360 | 6.0332 | 0.9530 |
| GBRT | 0.6296 | 0.8147 | 6.0733 | 0.9576 |

最佳性能以粗體突出顯示。



下載：下載高分辨率圖像 (229KB)

下載：下載全圖

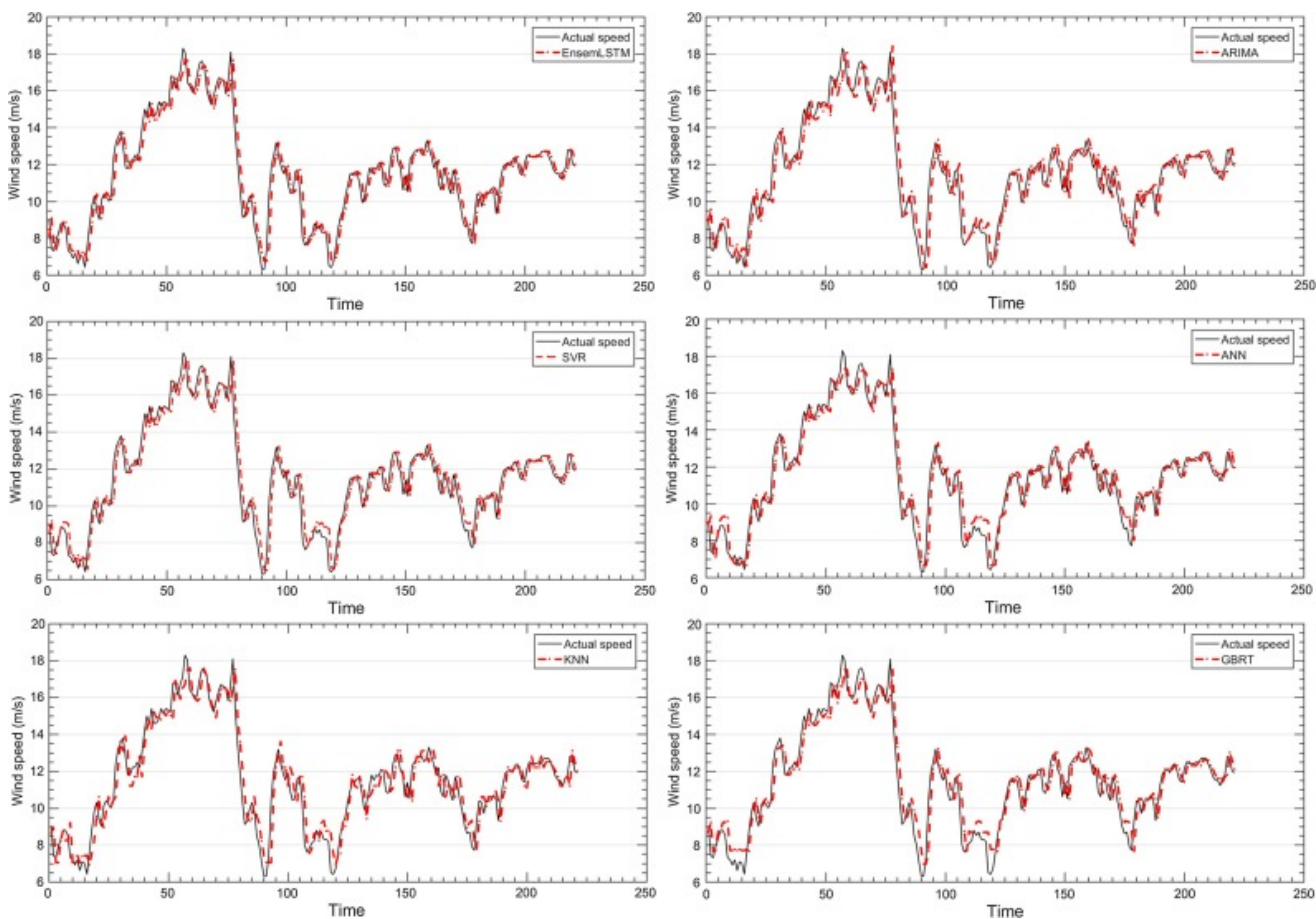
圖5。案例研究1中的預測效果比較

表4。案例研究1中的預測效果比較的統計檢驗。

| | 排名測試 | 酶標 | 有馬 | SVR | 人工神經網絡 | 知識網絡 | GBRT | 統計 | p值 |
|------|--------|--------|---------|--------|--------|--------|--------|---------|--------|
| MAE | 弗里德曼 | 1.000 | 5.867 | 2.333 | 3.467 | 4.500 | 3.833 | 130.815 | 0.0000 |
| | 弗里德曼對齊 | 16.633 | 162.400 | 52.567 | 92.667 | 116.83 | 101.90 | 120.118 | 0.0000 |
| | 四邊形 | 1.000 | 5.759 | 2.357 | 3.639 | 4.421 | 3.824 | 42.405 | 0.0000 |
| RMSE | 弗里德曼 | 1.000 | 5.867 | 2.400 | 3.600 | 4.567 | 3.567 | 125.412 | 0.0000 |
| | 弗里德曼對齊 | 17.767 | 162.267 | 58.267 | 95.833 | 117.87 | 91.000 | 115.456 | 0.0000 |
| | 四邊形 | 1.000 | 5.755 | 2.404 | 3.768 | 4.548 | 3.525 | 42.968 | 0.0000 |
| 瑪普 | 弗里德曼 | 1.000 | 5.800 | 2.333 | 3.833 | 3.733 | 4.300 | 104.787 | 0.0000 |
| | 弗里德曼對齊 | 17.723 | 158.400 | 53.167 | 102.53 | 101.90 | 109.77 | 112.599 | 0.0000 |
| | 四邊形 | 1.000 | 5.645 | 2.316 | 4.131 | 3.724 | 4.183 | 39.013 | 0.0000 |

| | 排名測試 | 酶標 | 有馬 | SVR | 人工神經網絡 | 知識網絡 | GBRT | 統計 | p值 |
|----|--------|---------------|---------|--------|--------|--------|--------|---------|--------|
| | 弗里德曼 | 1.000 | 5.900 | 2.200 | 3.633 | 4.733 | 3.533 | 195.558 | 0.0000 |
| [R | 弗里德曼對齊 | 20.233 | 163.400 | 48.800 | 97.467 | 127.00 | 86.100 | 125.848 | 0.0000 |
| | 四邊形 | 1.000 | 5.817 | 2.230 | 3.841 | 4.663 | 3.448 | 51.681 | 0.0000 |


最佳性能以粗體突出顯示。



[下載：下載高分辨率圖像 \(717KB \)](#)

[下載：下載全圖](#)


圖6。案例研究1中的風速預測結果。



[下載：下載高分辨率圖像 \(504KB \)](#)

[下載：下載全圖](#)

圖7。案例研究1中不同預測方法的預測殘差誤差的條形圖。



[下載：下載高分辨率圖像 \(305KB \)](#)

[下載：下載全圖](#)

圖8。案例研究1中不同預測方法的預測殘差折線圖

從表3和圖5中可以看出，與廣泛使用的預測方法相比，擬議的EnsemLSTM的性能更好，MAE的最小值為0.5746，RMSE的值為0.7552，MAPE的值為5.4167%，R的最大值為0.9619。最好的比較預測模型之一是SVR，MAE為0.5834，RMSE為0.7729，MAPE為5.4912%，R為0.9599，而最差的預測模型是ARIMA，MAE為0.6961，RMSE為0.9257，MAPE為6.5067%，R為0.9420。根據表4，所提出的EnsemLSTM在所有預測性能指標上的弗里德曼檢驗，弗里德曼比對檢驗和四邊形檢驗中也達到了最佳等級，顯著性水平為 $\alpha=0.0001$ 。此外，從圖的分析，如圖7和8所示，與其他預測結果相比，EnsemLSTM顯然顯示出更好的實際風速時間序列曲線擬合，並且殘留誤差更小。

為了驗證我們提出的EnsemLSTM改善風速預測性能的有效性，進行了整體學習頂層對預測性能的影響分析，並進行了EnsemLSTM和單個LSTM的比較。表5列出了不同頂層的影響，表6中顯示了集成模型和單個模型之間的比較。在表5中，不同的模型包括提議的EnsemLSTM，ANNLSTM（非線性學習頂層由ANN模型組成）和MeanLSTM（整體學習是平均預測結果）。從表5，我們發現EnsemLSTM可以實現更好的預測性能，這不僅表明SVRM優於ANN，而且還表明了非線性學習頂層的優勢。此外，從表6中可以清楚地看到，EnsemLSTM改進了單個LSTM的預測性能，與單個模型相比，顯示出強大的集成學習實力。

備註1

在案例研究1中，進行了至少提前10分鐘的短期風速預測，並且我們提出的EnsemLSTM比ARIMA，SVR，ANN，KNN和GBRT具有更好的預測性能，這表明動態序列的強大學習能力（風速時間）系列數據）。MAE，RMSE，MAPE和R的Friedman檢驗，Friedman Aligned檢驗和Quade檢驗也從統計角度證明了EnsemLSTM的優越性。而且，與ANNLSTM和MeanLSTM相比，EnsemLSTM中的SVRM非線性學習頂層表現出更好的整體學習性能。EnsemLSTM和六個單一預測模型LSTM1-LSTM6的比較也表明了集成學習的出色學習性能。

表5。在案例研究1中，不同的集成學習頂層對預測性能的影響。

| 不同型號 | MAE | RMSE | MAP (%) | [R |
|-----------|--------|--------|-----------|----------|
| 酶標 | 0.5746 | 0.7552 | 5.4167 | 0.961938 |
| 國家自然科學基金會 | 0.5850 | 0.7667 | 5.5145 | 0.961186 |
| 均值 | 0.5782 | 0.7585 | 5.4822 | 0.961890 |

最佳性能以粗體突出顯示。

表6。案例研究1中EnsemLSTM和單個LSTM的預測結果的比較。


| 不同型號 | MAE | RMSE | MAP (%) | [R |
|------|-----|------|-----------|--|
| | | | | FEEDBACK  |

| 不同型號 | MAE | RMSE | MAP (%) | [R |
|-------|---------------|---------------|---------------|-----------------|
| 酶標 | 0.5746 | 0.7552 | 5.4167 | 0.961938 |
| LSTM1 | 0.5834 | 0.7618 | 5.5520 | 0.961913 |
| LSTM2 | 0.5818 | 0.7613 | 5.5393 | 0.961861 |
| LSTM3 | 0.5794 | 0.7587 | 5.5017 | 0.961919 |
| LSTM4 | 0.5778 | 0.7605 | 5.4598 | 0.961652 |
| LSTM5 | 0.5776 | 0.7596 | 5.4494 | 0.961737 |
| LSTM6 | 0.5802 | 0.7625 | 5.4595 | 0.961764 |

最佳性能以粗體突出顯示。

5.3 。案例研究2：短期風速預測

在本案例研究2中，對提前一小時的短期風速預報進行了研究，並使用了2013年4月1日至2013年4月30日收集的平均一小時風速數據。以與案例研究1中討論的相同方式，將總共720個獲得的數據點分為兩部分。案例研究2中收集的風速顯示在圖9中，該數據集的統計信息顯示在表7中。表8顯示了案例研究2中不同比較預測方法的參數集。表9和表10還分別顯示了不同預測模型之間的預測結果和預測性能比較的統計檢驗。圖10可視化了預測結果的比較。從表9中可以看出，案例研究2中的四個預測性能指標變得比案例研究1中的計算指標差。可以很容易地理解，短期風速預測比最大短期風速更加複雜和困難。隨著風速不確定性的增加，預測時間範圍從十分鐘延長到一小時的時間進行預測。



下載：下載高分辨率圖像 (109KB)

下載：下載全圖

圖9。案例研究2中收集的風速

表7。案例研究中風速的統計信息2。

| 案例2：2013年4月1日至2013年4月30日收集的平均一小時風速數據 (m / s) | | | | | |
|--|--------|-------|-------|-------|-------|
| 數據集 | 最大限度 | 中位數 | 敏 | 意思是 | 標準差 |
| 整個數據集 | 23.383 | 8.092 | 0.617 | 8.687 | 4.322 |
| 訓練數據集 | 23.383 | 7.667 | 0.617 | 8.340 | 4.325 |
| 測試數據集 | 21.883 | 9.483 | 0.967 | 9.492 | 4.421 |

St.d：標準偏差。

表8。案例研究2中不同比較預測方法的參數集。

| 預測方法 | 參數集 |
|--------|---|
| 酶標 | $q = 30$ ，我 _{最大} = 1000 |
| 有馬 | $(p \cdot d \cdot q) = (2 \cdot 0 \cdot 1)$ |
| SVR | $\zeta = 22.77$ ， $\sigma^2 = 1$ |
| 人工神經網絡 | 1個具有10個神經元的隱藏層 |
| 知識網絡 | $K = 5$ |
| GBRT | 樹的最大深度設置為3，決策樹的數量設置為300 |

表9。案例研究2中預測模型的預測結果。

| 預測方法 | MAE | RMSE | 瑪普 | [R |
|--------|--------|--------|---------|--------|
| 酶標 | 1.1410 | 1.5335 | 17.1076 | 0.9375 |
| 有馬 | 1.3753 | 1.8337 | 20.7303 | 0.9098 |
| SVR | 1.1841 | 1.5766 | 17.7574 | 0.9338 |
| 人工神經網絡 | 1.1918 | 1.5784 | 18.1864 | 0.9340 |
| 知識網絡 | 1.2291 | 1.6223 | 17.9257 | 0.9297 |


| 預測方法 | MAE | RMSE | 瑪普 | [R |
|------|--------|--------|---------|--------|
| GBRT | 1.2143 | 1.5806 | 18.6117 | 0.9341 |

最佳性能以粗體突出顯示。

表10。案例研究2中的預測效果比較的統計檢驗。

| | 排名測試 | 酶標 | 有馬 | SVR | 人工神經網絡 | 知識網絡 | GBRT | 統計 | p值 |
|------|--------|---------------|---------|--------|--------|--------|--------|---------|--------|
| MAE | 弗里德曼 | 1.000 | 6.000 | 2.400 | 2.933 | 4.767 | 3.867 | 238.732 | 0.0000 |
| | 弗里德曼對齊 | 16.033 | 165.500 | 57.067 | 72.100 | 130.27 | 102.03 | 133.168 | 0.0000 |
| | 四邊形 | 1.065 | 6.000 | 2.439 | 2.895 | 4.757 | 3.845 | 58.790 | 0.0000 |
| RMSE | 弗里德曼 | 1.000 | 6.000 | 2.567 | 2.900 | 4.867 | 3.667 | 241.907 | 0.0000 |
| | 弗里德曼對齊 | 15.500 | 162.500 | 69.433 | 71.900 | 133.80 | 86.867 | 130.042 | 0.0000 |
| | 四邊形 | 1.000 | 6.000 | 2.510 | 3.086 | 4.796 | 3.609 | 58.435 | 0.0000 |
| 瑪普 | 弗里德曼 | 1.100 | 5.967 | 2.567 | 3.167 | 3.533 | 4.667 | 124.272 | 0.0000 |
| | 弗里德曼對齊 | 17.733 | 164.500 | 65.833 | 84.700 | 84.067 | 126.17 | 118.344 | 0.0000 |
| | 四邊形 | 1.161 | 5.935 | 2.594 | 3.125 | 3.542 | 4.643 | 42.701 | 0.0000 |
| [R | 弗里德曼 | 1.033 | 6.000 | 3.633 | 2.867 | 4.900 | 2.567 | 235.936 | 0.0000 |
| | 弗里德曼對齊 | 15.567 | 165.500 | 86.433 | 71.033 | 134.53 | 69.933 | 130.832 | 0.0000 |
| | 四邊形 | 1.037 | 6.000 | 3.596 | 3.026 | 4.845 | 2.497 | 58.732 | 0.0000 |

最佳性能以粗體突出顯示。

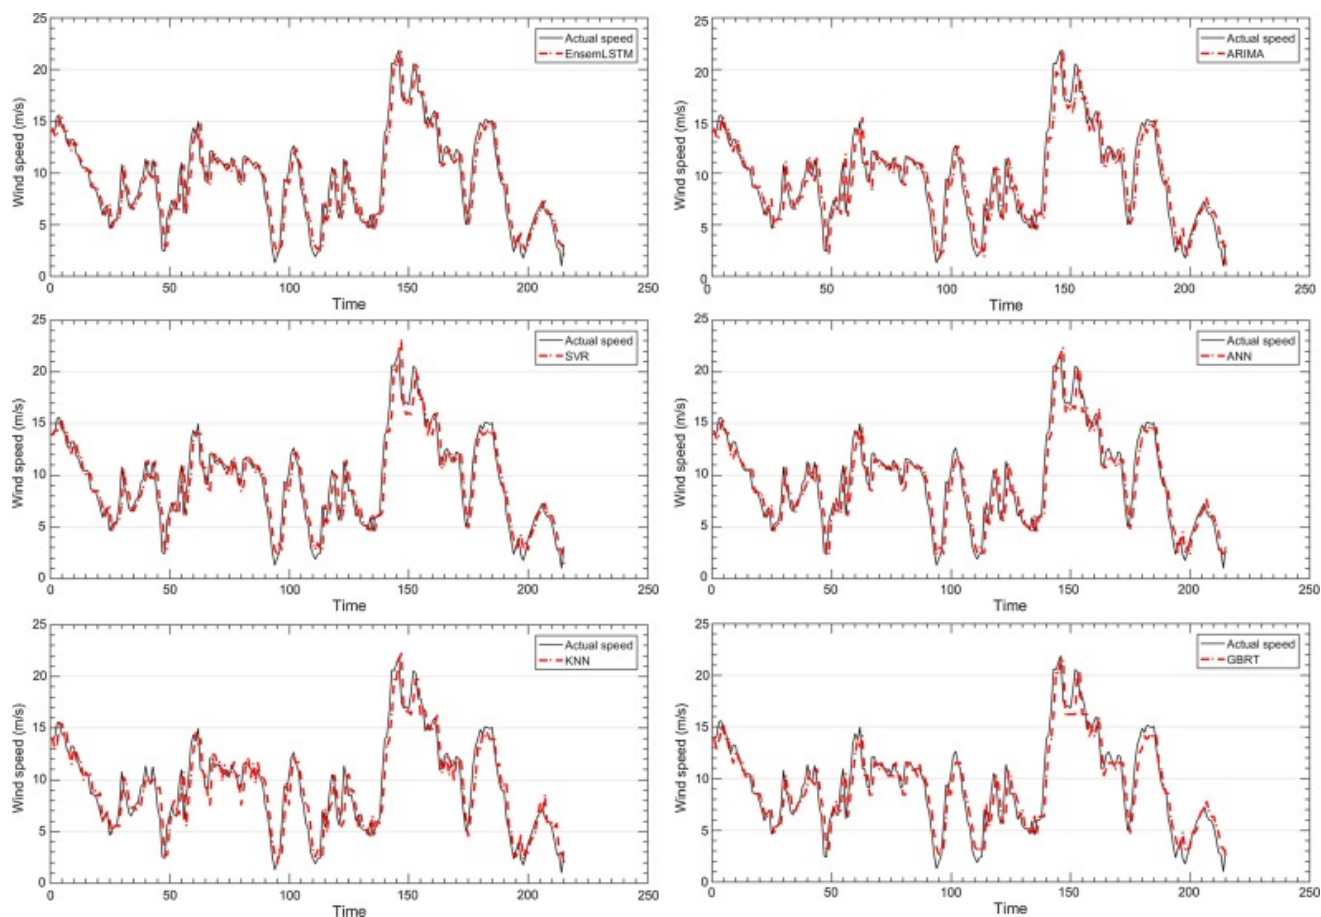


下載：下載高分辨率圖像 (212KB)

下載：下載全圖

圖10。案例研究2中的預測效果比較。

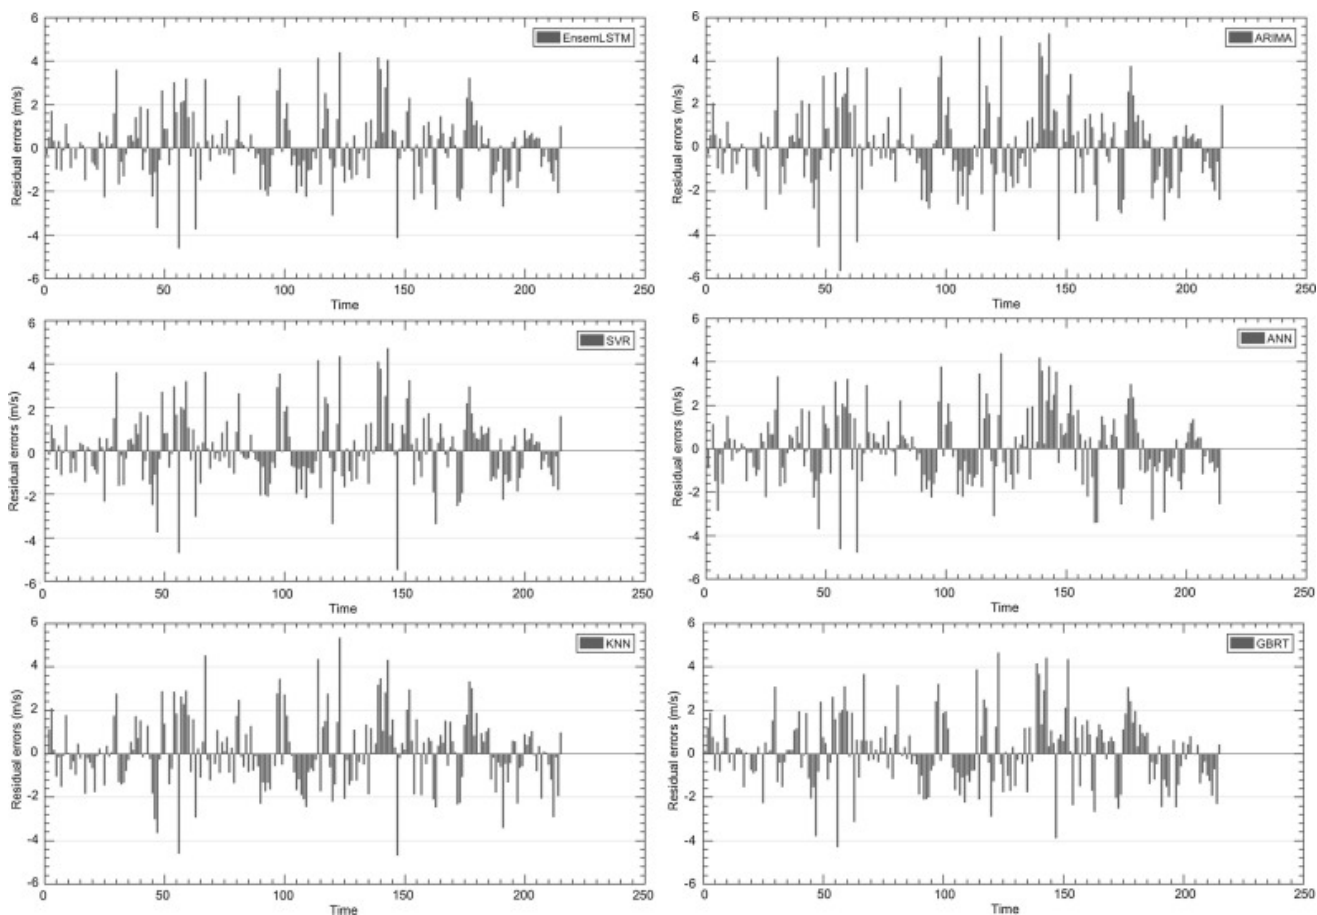
與案例研究1的結果類似，表9和圖10顯示，對於短期風速預測，擬議的EnsemLSTM優於這些比較的預測模型，MAE的最小值為1.1410，RMSE的最小值為1.5335，MAPE的最小值為17.1076%，而R的最大值為0.9375，而比較的預測模型的最佳預測性能指標分別為：對於SVR，MAE為1.1841；對於SVR，RMSE為1.5766；對於SVR，MAPE為17.7574%；對於GBRT，R為0.9341。此外，EnsemLSTM在統計測試中也排名第一，對於表10的短期風速預測，顯著性水平為 $\alpha=0.0001$ 。圖11繪製了案例研究2中的預測結果。12和圖13分別示出了針對不同預測方法的預測殘差的條形圖和折線圖。無花果 11，12和13表明，風速由EnsemLSTM顯示預測在案例2中的實際風速和預製件較少的殘餘錯誤的更多的相似性。



[下載：下載高分辨率圖像 \(703KB \)](#)

[下載：下載全圖](#)


圖11。案例研究2中的風速預測結果。



[下載：下載高分辨率圖像 \(515KB \)](#)

[下載：下載全圖](#)

圖12。案例研究2中不同預測方法的預測殘差誤差的條形圖。



[下載：下載高分辨率圖像 \(330KB \)](#)

[下載：下載全圖](#)

圖13。案例研究2中不同預測方法的預測殘差折線圖

表11顯示了案例研究2中不同集合學習頂層對預測性能的影響，表12顯示了EnsemLSTM和單個LSTM之間的比較。表11和表12證明了我們提出的EnsemLSTM比ANNLSTM，MeanLSTM和單個LSTM表現出更好的風速預測，這得益於SVRM的非線性學習集成頂層。

備註2

案例2中進行了提前一小時的短期風速預測，這比案例1中的提前十分鐘最大短期風速預測更為複雜和困難。2，實驗結果的統計測試表明，我們提出的EnsemLSTM仍然優於ARIMA，SVR，ANN，KNN和GBRT。此外，案例研究2還驗證了EnsemLSTM的預測性能要優於ANNLSTM，MeanLSTM和單個LSTM，這意味著非線性學習頂層和集成學習的強大學習能力。

表11。在案例研究2中，不同的集成學習頂層對預測性能的影響。

| 不同型號 | MAE | RMSE | MAP (%) | [R |
|-----------|---------------|---------------|----------------|-----------------|
| 酶標 | 1.1410 | 1.5335 | 17.1076 | 0.937498 |
| 國家自然科學基金會 | 1.1660 | 1.5610 | 17.8027 | 0.936749 |
| 均值 | 1.1446 | 1.5451 | 17.5856 | 0.937349 |

最佳性能以粗體突出顯示。

表12。案例研究2中EnsemLSTM和單個LSTM的預測結果的比較。

| 不同型號 | MAE | RMSE | MAP (%) | [R |
|-------|---------------|---------------|----------------|-----------------|
| 酶標 | 1.1410 | 1.5335 | 17.1076 | 0.937498 |
| LSTM1 | 1.1503 | 1.5443 | 17.8296 | 0.937486 |
| LSTM2 | 1.1437 | 1.5463 | 17.4906 | 0.937257 |
| LSTM3 | 1.1451 | 1.5483 | 17.4886 | 0.937313 |
| LSTM4 | 1.1461 | 1.5466 | 17.6182 | 0.937308 |
| LSTM5 | 1.1471 | 1.5483 | 17.5832 | 0.937272 |
| LSTM6 | 1.1494 | 1.5502 | 17.6746 | 0.937261 |

最佳性能以粗體突出顯示。

5.4 。討論與比較

本節重點討論提議的EnsemLSTM與其他常規預測模型之間的討論和比較。根據最大短期風速預測和短期風速預測的實驗結果，我們可以發現，在比較模型（即ARIMA，SVR，ANN，KNN和GBRT。表4和表10中的相關統計測試證明了EnsemLSTM的有效性。此外，從所提出方法的結構來看，EnsemLSTM的預測能力取決於LSTM和非線性學習集合頂層。為了提高單個LSTM的泛化能力和魯棒性，對LSTM進行了多種多樣的集成學習本文介紹了隱藏層和神經元。並進行了表5，表6和表11，表12的分析還表明，由EO優化的SVRM集成學習頂層優於ANNLSTM，MeanLSTM和單個LSTM。另一方面，由於ARIMA的線性特徵和SVR，ANN，KNN和GBRT的簡單計算，所提出的基於深度學習的集成模型比它們複雜。此外，該方法的預測能力可能會受到整體學習結構的影響，並且可以通過為特定數據採用更合適的結構來增強。因此，我們得出的結論是，本文提出的EnsemLSTM是有效且有前途的，可以看作是風速預測的另一種可靠技術。

6 。結論與未來工作

風速預測是風能發電，轉換和運行中必不可少的問題，已經引起了人們的廣泛關注。本文介紹了一種基於非線性學習集合的基於LSTM，SVRM和EO的深度學習時間序列預測的風速預測方法。在提議的EnsemLSTM中，具有不同隱藏層和神經元的LSTM簇首先分別學習風速時間序列信息。然後，將LSTM的預測匯總到由SVRM組成的非線性學習回歸頂層中，並引入EO來優化頂層參數。最後，最終的集合風速預報是由微調的頂層給出的。為了驗證所提議的EnsemLSTM的有效性，從風電場中收集了兩個案例研究數據在中國內蒙古，我們將最大風速預報提前十分鐘，將短期風速預報提前一小時。與其他流行的預測模型（包括ARIMA，SVR，ANN，KNN和GBRT）相比，建議的EnsemLSTM可以實現更好的預測性能，其MAE，RMSE和MAPE的最小值和R的最大值。此外，EnsemLSTM還實現了在實驗結果的統計測試（包括Friedman，Friedman Aligned和Quade測試）中排名最高。此外，通過分析整體學習頂層對預測性能的影響以及EnsemLSTM和單個LSTM的比較表明，由EO優化的SVRM非線性學習頂層優於ANNLSTM，MeanLSTM和單個LSTM。

本文研究了用於風速預測的單變量時間序列預測。在不久的將來，將研究基於深度學習算法的多元時間序列預測，該算法使用更多相互關聯的功能（例如天氣條件，人為因素和電力系統狀態）來進行更複雜的風速預測。另一方面，作者還將嘗試研究更有效的整體學習結構，以提高模型的預測能力。

致謝

這項工作得到了中國自然科學基金（批准號61573095）和浙江省自然科學基金（批准號LY16F030011和LZ16E050002）的支持。

附錄A

算法：EnsemLSTM

Input: The whole wind speed time series data

Output: The ensemble prediction wind speed data and forecasting performance indices

- 1: The whole wind speed time series data is split into two parts i.e. the train dataset and test dataset.
 - 2: The parameters of EO: the total number of variables N is set as 2, the PLM parameter q is set as 30 and the maximum number of iterations I_{\max} is set as 1000.
 - 3: A cluster of LSTMs with diverse numbers of hidden layers and neurons in each hidden layer are trained on the train dataset and independent predictions of LSTMs for wind speed forecasting are made.
 - 4: Predictions of LSTMs are aggregated into a nonlinear-learning regression top-layer composed of SVRM. // *Parameters of SVRM are optimized by EO.*
 - 5: Generate an initial solution S with two components randomly, where $S = [C, \sigma]$, $C \in [0, 1000]$, $\sigma \in [0, 1]$, set $S_{\text{best}} = S$, compute the fitness $C(S_{\text{best}}) = C(S)$ i.e. the MSE of 3-cross-validation of SVRM adopting the C and σ of S on the train dataset. // *C and σ represent the punishment coefficient and kernel parameter of SVRM, respectively.*
 - 6: **WHILE** the maximum number of iterations I_{\max} is not satisfied **DO**
 - 7: **FOR** $i \leftarrow 1$ **TO** N **DO**
 - 8: Generate the solution S_i by mutating the component i ($1 \leq i \leq N$) with PLM and keeping the others unchanged.
 - 9: Compute the fitness $C(S_i)$ i.e. the MSE of 3-cross-validation of SVRM adopting the C and σ of S_i on the train dataset.
-

```

10:   Evaluate the local fitness  $\lambda_i = C(S_i) - C_{best}$ .
11: ENDFOR
12:   Rank all the components according to  $\lambda_i$ .
13:   Set the worst solution from  $S_i$  as  $S_{new}$ .
14:   IF  $C(S_{new}) < C(S_{best})$  THEN
        $S_{best} = S_{new}$ .
        $C(S_{best}) = C(S_{new})$ .
15:   ENDIF
16:   The current solution  $S$  is replaced by  $S_{new}$  unconditionally.
17: ENDWHILE

18: The best solution  $S_{best}$  representing the optimal parameter  $C$  and  $\sigma$  of SVRM is obtained.


19: The final ensemble prediction for wind speed is output by the fine-tuning top-layer i.e. SVRM
    optimized by EO.

20: Forecasting performance indices are calculated based on the test dataset and ensemble prediction
    wind speed data.

```

[推薦文章](#)
[引文 \(111 \)](#)

References

- [1] <http://www.gwec.net/>.
[Google Scholar](#)
- [2] V. Khare, S. Nema, P. Baredar
Solar-wind hybrid renewable energy system: a review
 Renew Sustain Energy Rev, 58 (2016), pp. 23-33
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [3] M. Al-falahi, S. Jayasinghe, H. Enshaei
A review on recent size optimization methodologies for standalone solar and wind hybrid renewable energy system

Energy Convers Manag, 143 (2017), pp. 252-274

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[4] A. Tascikaraoglu, M. Uzunoglu

A review of combined approaches for prediction of short-term wind speed and power

Renew Sustain Energy Rev, 34 (2014), pp. 243-254

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[5] H. Liu, H. Tian, Y. Li

An EMD-recursive ARIMA method to predict wind speed for railway strong wind warning system

J Wind Eng Ind Aerodyn, 141 (2015), pp. 27-38

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[6] R. Kavasseri, K. Seetharaman

Day-ahead wind speed forecasting using f-ARIMA models

Renew Energy, 34 (2009), pp. 1388-1393

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[7] C. Ren, N. An, J. Wang, L. Li, B. Hu, D. Shang

Optimal parameters selection for BP neural network based on particle swarm optimization: a case study of wind speed forecasting

Knowledge-Based Syst, 56 (2014), pp. 226-239

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[8] A. Aghajani, R. Kazemzadeh, A. Ebrahimi

A novel hybrid approach for predicting wind farm power production based on wavelet transform, hybrid neural networks and imperialist competitive algorithm

Energy Convers Manag, 121 (2016), pp. 232-240

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[9] C. Zhang, H. Wei, L. Xie, Y. Shen, K. Zhang

Direct interval forecasting of wind speed using radial basis function neural networks in a multi-objective optimization framework

Neurocomputing, 205 (2016), pp. 53-63

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[10] G. Li, J. Shi

Applications of Bayesian methods in wind energy conversion systems






Renew Energy, 43 (2012), pp. 1-8






[Article](#)  [Download PDF](#) [CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[11] C. Zhang, J. Zhou, C. Li, W. Fu, T. Peng

A compound structure of ELM based on feature selection and parameter optimization using hybrid backtracking search algorithm for wind speed forecasting



Energy Convers Manag, 143 (2017), pp. 360-376

- [12] G. Chang, H. Lu, Y. Chang, Y. Lee
An improved neural network-based approach for short-term wind speed and power forecast
Renew Energy, 105 (2017), pp. 301-311
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [13] Y. Noorollahi, M.A. Jokar, A. Kalhor
Using artificial neural networks for temporal and spatial wind speed forecasting in Iran
Energy Convers Manag, 115 (2016), pp. 17-25
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [14] X. Ma, Y. Jin, Q. Dong
A generalized dynamic fuzzy neural network based on singular spectrum analysis optimized by brain storm optimization for short-term wind speed forecasting
Appl Soft Comput J, 54 (2017), pp. 296-312
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [15] P. Jiang, Y. Wang, J. Wang
Short-term wind speed forecasting using a hybrid model
Energy, 119 (2017), pp. 561-577
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [16] K. Chen, J. Yu
Short-term wind speed prediction using an unscented Kalman filter based state-space support vector regression approach
Appl Energy, 113 (2014), pp. 690-705
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [17] L. Xiao, W. Shao, M. Yu, J. Ma, C. Jin
Research and application of a combined model based on multi-objective optimization for electrical load forecasting
Energy, 119 (2017), pp. 1057-1074
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [18] L. Xiao, J. Wang, Y. Dong, J. Wu
Combined forecasting models for wind energy forecasting: a case study in China
Renew Sustain Energy Rev, 44 (2015), pp. 271-288
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [19] J. Wang, J. Heng, L. Xiao, C. Wang
Research and application of a combined model based on multi-objective optimization for multi-step ahead wind speed forecasting
Energy, 125 (2017), pp. 591-613

- [20] J. Wang, J. Hu
A robust combination approach for short-term wind speed forecasting and analysis – combination of the ARIMA (Autoregressive Integrated Moving Average), ELM (Extreme Learning Machine), SVM (Support Vector Machine) and LSSVM (Least Square SVM) forecasts using a GPR (Gaussian Process Regression) model
Energy, 93 (2015), pp. 41-56
[Article](#)  [Download PDF](#) [CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [21] M. Långkvist, L. Karlsson, A. Loutfi
A review of unsupervised feature learning and deep learning for time-series modeling
Pattern Recognit Lett, 42 (2014), pp. 11-24
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [22] Y. Lv, Y. Duan, W. Kang, Z. Li, F. Wang
Traffic flow prediction with big data: a deep learning approach
IEEE Trans Intell Transp Syst, 16 (2014), pp. 865-873
[Google Scholar](#)
- [23] X. Qiu, Y. Ren, P.N. Suganthan, G. Amaratunga
Empirical mode decomposition based ensemble deep learning for load demand time series forecasting
Appl Soft Comput, 54 (2017), pp. 246-255
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [24] Q. Hu, R. Zhang, Y. Zhou
Transfer learning for short-term wind speed prediction with deep neural networks
Renew Energy, 85 (2016), pp. 83-95
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [25] M. Khodayar, O. Kaynak, M.E. Khodayar
Rough deep neural architecture for short-term wind speed forecasting
IEEE Trans Ind Inform, 13 (2017), pp. 2770-2779
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [26] H. Wang, G. Wang, G. Li, J. Peng, Y. Liu
Deep belief network based deterministic and probabilistic wind speed forecasting approach
Appl Energy, 182 (2016), pp. 80-93
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [27] Y. Ren, L. Zhang, P.N. Suganthan
Ensemble classification and regression: Recent developments, applications and future directions
IEEE Comput Intell Mag, 11 (2016), pp. 41-53

- [28] W. Yang, J. Wang, R. Wang
Research and application of a novel hybrid model based on data selection and artificial intelligence algorithm for short term load forecasting
Entropy, 19 (2) (2017), p. 52
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [29] X. Zhang, J. Wang, K. Zhang
Short-term electric load forecasting based on singular spectrum analysis and support vector machine optimized by Cuckoo search algorithm
Electr Power Syst Res, 146 (2017), pp. 270-285
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [30] Y. Xu, W. Yang, J. Wang
Air quality early-warning system for cities in China
Atmos Environ, 148 (2017), pp. 239-257
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [31] S. Hochreiter, J. Schmidhuber
Long short-term memory
Neural Comput, 9 (1997), pp. 1-32
[View Record in Scopus](#) [Google Scholar](#)
- [32] T.N. Sainath, O. Vinyals, A. Senior, H. Sak
Convolutional, long short-term memory, fully connected deep neural networks
IEEE Int Conf Acoust Speech Signal Process, 2015 (2015), pp. 4580-4584
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [33] S. Boettcher, A. Percus
Nature's way of optimizing
Artif Intell, 119 (2000), pp. 275-286
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [34] S. Boettcher, A.G. Percus
Optimization with extremal dynamics
Phys Rev Lett, 86 (2001), pp. 5211-5214
[View Record in Scopus](#) [Google Scholar](#)
- [35] P. Bak, K. Sneppen
Punctuated equilibrium and criticality in a simple model of evolution
Phys Rev Lett, 71 (1993), pp. 4083-4086
[View Record in Scopus](#) [Google Scholar](#)
- [36] Lu Y, Chen M, Chen Y. Studies on extremal optimization and its applications in solving realworld optimization problems. In: Foci; 2007. p. 162–8.

- [37] Lu Y, Chen Y, Chen M, Chen P, Zeng G. Extremal optimization: fundamentals, algorithms, and applications. CRC Press & Chemical Industry Press; 2016.
[Google Scholar](#)
- [38] G. Zeng, J. Chen, L. Li, M. Chen, L. Wu, Y. Dai, *et al.*
An improved multi-objective population-based extremal optimization algorithm with polynomial mutation
Inf Sci, 330 (2016), pp. 49-73
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [39] G. Zeng, J. Chen, Y. Dai, L. Li, C. Zheng, M. Chen
Design of fractional order PID controller for automatic regulator voltage system based on multi-objective extremal optimization
Neurocomputing, 160 (2015), pp. 173-184
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [40] G. Zeng, J. Chen, M. Chen, Y. Dai, L. Li, K. Lu, *et al.*
Design of multivariable PID controllers using real-coded population-based extremal optimization
Neurocomputing, 151 (2015), pp. 1343-1353
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [41] K. Lu, W. Zhou, G. Zeng, W. Du
Design of PID controller based on a self-adaptive state-space predictive functional control using extremal optimization method
J Franklin Inst, 355 (2018), pp. 2197-2220
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [42] I. Goodfellow, Y. Bengio, A. Courville
Deep Learning
MIT Press (2016)
[Google Scholar](#)
- [43] Y. Wu, M. Yuan, S. Dong, L. Lin, Y. Liu
Remaining useful life estimation of engineered systems using vanilla LSTM neural networks
Neurocomputing, 275 (2018), pp. 167-179
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [44] J. Shi, J. Guo, S. Zheng
Evaluation of hybrid forecasting approaches for wind speed and power generation time series
Renew Sustain Energy Rev, 16 (2012), pp. 3471-3480
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

- [45] J. Zhou, J. Shi, G. Li
Fine tuning support vector machines for short-term wind speed forecasting
Energy Convers Manag, 52 (2011), pp. 1990-1998
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [46] <http://scikit-learn.org/>.
[Google Scholar](#)
- [47] <https://keras.io/>.
[Google Scholar](#)
- [48] J. Derrac, S. García, D. Molina, F. Herrera
關於使用非參數統計檢驗作為比較進化和群體智能算法的方法的實用教程
群EVOL COMPUT · 1 (2011) · 第3 - 18
[文章](#)  [下載PDF](#) [查看Scopus中的記錄](#) [谷歌學術](#)

[查看摘要](#)

©2018 Elsevier Ltd.保留所有權利。



[關於ScienceDirect](#)

[遠程訪問](#)

[購物車](#)

[廣告](#)

[聯繫與支持](#)

[條款和條件](#)

[隱私政策](#)

我們使用Cookie來幫助提供和增強我們的服務，並量身定制內容和廣告。繼續，您同意使用Cookies。

版權所有© 2021 Elsevier BV或其許可方或貢獻者。ScienceDirect®是Elsevier BV的註冊商標

ScienceDirect®是Elsevier BV的註冊商標



FEEDBACK 